Entrega 2: Preparación y Análisis de los Datos

Objetivo:
A partir del dataset FAIR publicado en Hugging Face en la Entrega 1, realizar la preparación, exploración y generación de indicadores básicos que permitan formular hipótesis de análisis.

Requisitos:

- **Procesamiento y limpieza:**
  - Documentar en data_cleaning.md las transformaciones aplicadas (eliminación de duplicados, normalización de texto, etc.).
  - Guardar datos procesados en data/processed/.
- **Indicadores obligatorios (mínimos):**
  - **Volumen temporal de publicaciones**: conteo por hora, día, semana o mes.
  - **Sentimiento medio agregado**: cálculo de polaridad (positivo/negativo/neutro) por intervalo temporal, usando un modelo en español predefinido.
  - **Distribución de tópicos**: aplicar un modelo de tópicos (ej. LDA o BERTopic) y mostrar la proporción de tópicos por intervalo temporal.
- **Indicadores opcionales (elegir sólo 1):**
  - **Diversidad léxica**: índice de riqueza de vocabulario o entropía de Shannon por intervalo.
  - **Similitud semántica**: similitud promedio entre embeddings de textos en intervalos temporales.
  - **Palabras clave**: detección de términos cuya frecuencia aumenta súbitamente.
  - **Clasificación temática asistida por LLM**: categorización de textos en clases definidas por el grupo.
- **Hipótesis:**
  - Formular 1 hipótesis clara y verificable, basada en los indicadores obtenidos.
  - Ejemplos:
    - "El volumen de noticias sobre salud mental aumenta los domingos."
    - "La media de sentimiento en tuits sobre transporte público es más negativa en horas punta."
    - "La proporción del tópico *economía* en titulares crece durante los meses de campaña electoral."
- **Entregables:**
  - Carpeta data/processed/ con los datos limpios.
  - Documento motivation.md con:
    - Objetivo general del proyecto.
    - Preguntas de investigación o hipótesis planteadas.
    - Justificación del dataset y de los indicadores calculados.
    - Limitaciones o posibles sesgos detectados.